

Trabalho Final | FLS5028

Bernardo Franco

2026-07-19

Perguntas obrigatórias (graduação e pós-graduação)

1. Artigo, pergunta e unidade de análise

Responda em texto:

1. Qual é a pergunta geral do artigo?

O artigo investiga como se dão as nomeações a cargos públicos de médio e alto escalão no Executivo Federal brasileiro, questionando se os perfis dos nomeados variam conforme a natureza das políticas de cada pasta. O ponto de fundo é testar dois aspectos da literatura: as previsões teóricas sobre a relação entre área de política e perfil da burocracia, e a validade de usar a filiação partidária como *proxy* para identificar atuação política.

2. Qual é a unidade de análise da base?

A unidade de análise é a nomeação.

3. O que significa uma linha da base?

Cada linha corresponde a uma nomeação de um funcionário para um cargo comissionado (DAS ou FCPE) de níveis 4 a 6, com as informações sobre o perfil e a trajetória daquela pessoa no momento em que foi nomeada.

4. Por que a mesma pessoa pode aparecer mais de uma vez?

A mesma pessoa pode aparecer mais de uma vez porque a unidade é a nomeação (e não o indivíduo). Se a mesma pessoa foi nomeada para mais de um cargo dentro do período analisado, ela gera uma linha para cada nomeação. Por isso a base tem 890 observações referentes a 568 funcionários públicos.

5. Quais são as duas pastas comparadas no artigo?

As suas pastas comparadas no artigo são a da cultura (Ministério da Cultura/Secretaria Especial da Cultura) e da agricultura (Ministério da Agricultura, Pecuária e Abastecimento).

2. Leitura e validação dos dados

Importe a base no R e apresente:

1. Número de linhas e colunas.

```
# Carregar os pacotes básicos
```

```
library(readxl)
library(dplyr)
```

```
##
## Anexando pacote: 'dplyr'

## Os seguintes objetos são mascarados por 'package:stats':
##
##     filter, lag

## Os seguintes objetos são mascarados por 'package:base':
##
##     intersect, setdiff, setequal, union
```

```
library(stringr)
library(ggplot2)
library(ggpattern)
library(RColorBrewer)
library(kableExtra)
```

```
##
## Anexando pacote: 'kableExtra'
```

```
## O seguinte objeto é mascarado por 'package:dplyr':
##
##     group_rows
```

```
# Ler a base de dados do clone criado no repositório (pasta '/dados')

df <- read_xlsx("../dados/BASE_cargos2.xlsx", "BASE_cargos", na = "NA")

codebook <- read_xlsx("../dados/BASE_cargos2.xlsx", "Codebook")

# Revelar o número de linhas e colunas do df

c(linhas = nrow(df), colunas = ncol(df))
```

```
## linhas colunas
##      1038      26
```

2. Nomes das variáveis.

```
# Mostrar o nome das colunas do df

names(df)
```

```
## [1] "orgao_sup"      "setor"          "chave"          "id"
## [5] "cargo"          "funcao"         "nivel"          "instr"
## [9] "area"          "inst_ensino"    "inst_origem"    "car_pub"
## [13] "partido"        "cargo_ele"      "lid_part"       "exp_adm"
## [17] "exp_car"        "exp_mer"        "exp_soc"        "UF*"
## [21] "partido_pr"     "partido_ministro" "indicacao"      "entrada"
## [25] "saida"          "perm"
```

3. Número de observações por `orgao_sup`.

```
# Ler o número de observações por 'orgao_sup' em df
df |>
  count(orgao_sup, name = "n")
```

```
## # A tibble: 3 x 2
##   orgao_sup     n
##   <chr>     <int>
## 1 mapa       525
## 2 mcti       148
## 3 minc       365
```

4. Número de valores ausentes em pelo menos cinco variáveis relevantes.

```
# Contar o número de valores ausentes em variáveis relevantes em df
df |>
  summarise(across(c(nivel, instr, area, inst_ensino, inst_origem), ~ sum(is.na(.)),
    ↪ .names = "na_{col}"))
```

```
## # A tibble: 1 x 5
##   na_nivel na_instr na_area na_inst_ensino na_inst_origem
##   <int>    <int>    <int>         <int>         <int>
## 1         0        95       183           266           269
```

5. Uma checagem dos valores observados em `exp_adm`, `exp_car`, `nivel`, `instr` e `indicacao`.

```
# Checar valores observados em 'exp_adm', 'exp_car', 'nivel', 'instr' e 'indicacao' em df
df |>
  group_by(exp_adm) |>
  summarize(n = n(), .groups = "drop")
```

```
## # A tibble: 5 x 2
##   exp_adm     n
##   <chr>     <int>
## 1 0         88
## 2 1        935
## 3 3          1
## 4 `1         3
## 5 <NA>       11
```

```
df |>
  group_by(exp_car) |>
  summarize(n = n(), .groups = "drop")
```

```
## # A tibble: 6 x 2
##   exp_car     n
```

```
##      <dbl> <int>
## 1      0    147
## 2      1     51
## 3      2      2
## 4      3    509
## 5      5    253
## 6     NA     76
```

```
df |>
  group_by(nivel) |>
  summarize(n = n(), .groups = "drop")
```

```
## # A tibble: 3 x 2
##   nivel      n
##   <dbl> <int>
## 1     4    652
## 2     5    275
## 3     6    111
```

```
df |>
  group_by(instr) |>
  summarize(n = n(), .groups = "drop")
```

```
## # A tibble: 7 x 2
##   instr      n
##   <chr>   <int>
## 1 doutorado    159
## 2 especializacao 203
## 3 graduacao      1
## 4 mestrado     259
## 5 superior     297
## 6 tecnico      24
## 7 <NA>         95
```

```
df |>
  group_by(indicacao) |>
  summarize(n = n(), .groups = "drop")
```

```
## # A tibble: 4 x 2
##   indicacao      n
##   <chr>   <int>
## 1 Bolsonaro    396
## 2 Lula         87
## 3 Rousseff     351
## 4 Temer        204
```

Depois, explique qualquer problema encontrado. Por exemplo, algumas variáveis que deveriam ser binárias podem ter valores inesperados. Diga como você tratou esses casos.

De acordo com o *codebook* do artigo, a variável `exp_adm` é binária, podendo assumir, portanto, apenas os valores 0 e 1. Na base de dados, há, no entanto, uma linha anotada com o valor 3 e três outras anotadas com a *string* "1". Para corrigir esse problema, aquela primeira foi alterada para NA e estas últimas foram cambiadas para 1, mediante a execução das linhas de código abaixo:

```

# Corrigir valores inadequados na variável 'exp_adm' em df

df <- df |>
  mutate(
    exp_adm = str_remove_all(as.character(exp_adm), "`"),
    exp_adm = case_when(
      exp_adm == "3" ~ NA_real_,
      TRUE ~ as.numeric(exp_adm)
    )
  )

## Validar correção de valores inadequados na variável 'exp_adm' em df

df |>
  group_by(exp_adm) |>
  summarize(n = n(), .groups = "drop")

```

```

## # A tibble: 3 x 2
##   exp_adm      n
##   <dbl> <int>
## 1      0     88
## 2      1    938
## 3     NA     12

```

Problema análogo foi notado com relação à variável `exp_car`. Segundo o codebook, a variável deveria assumir apenas os valores 1 (experiência prévia em cargos DAS/FCPE 1-2), 2 (experiência prévia em cargos DAS/FCPE 3-4) e 3 (experiência prévia em cargos DAS 5-6). Entretanto, na base de dados, observaram-se cinco valores únicos (0, 1, 2, 3 e 5). A hipótese preliminar para realizar a imputação foi a de que — à exceção de duas linhas classificadas como 2 — a anotação teria sido feita inadvertidamente tendo em mente os limites inferiores dos intervalos de classe (*i.e.*, 1 designaria “experiência prévia em cargos DAS/FCPE 1-2”, 3 designaria “experiência prévia em cargos DAS/FCPE 3-4” e 5 designaria “experiência prévia em cargos DAS 5-6”). Por sua vez, 0 significaria ausência de experiência prévia na administração pública.

Para testar essa hipótese, cruzou-se `exp_car` com `nivel`. Caso os valores 3 e 5 fossem, em realidade, codificações concorrentes para o mesmo intervalo de classe “experiência prévia em cargos DAS 5-6” (hipótese alternativa), teriam, cada qual, distribuições parecidas entre os níveis.

```

# Testar hipótese preliminar para imputação de dados na variável 'exp_car'

df |>
  count(nivel, exp_car) |>
  group_by(nivel) |>
  mutate(prop = round(n / sum(n), 3)) |>
  arrange(nivel, exp_car)

```

```

## # A tibble: 15 x 4
## # Groups:   nivel [3]
##   nivel exp_car      n prop
##   <dbl> <dbl> <int> <dbl>
## 1     4      0     75 0.115
## 2     4      1     45 0.069
## 3     4      2      2 0.003
## 4     4      3    414 0.635

```

```
## 5      4      5      77 0.118
## 6      4     NA      39 0.06
## 7      5      0      46 0.167
## 8      5      1       6 0.022
## 9      5      3      83 0.302
## 10     5      5     120 0.436
## 11     5     NA      20 0.073
## 12     6      0      26 0.234
## 13     6      3      12 0.108
## 14     6      5      56 0.505
## 15     6     NA      17 0.153
```

```
## Verificar graficamente os resultados do teste de hipótese
```

```
rotulos <- c(
  "0" = "0 (Sem Exp. Pr.)",
  "1" = "1 (Exp. Pr. DAS/FCPE 1-2)",
  "2" = "2 (Exp. Pr. DAS/FCPE 3-4)",
  "3" = "3 (Exp. Pr. DAS/FCPE 3-4)",
  "5" = "5 (Exp. Pr. DAS 5-6)"
)

cores <- c(
  "0" = "white",
  "1" = "#E0E0E0",
  "2" = "#C0C0C0",
  "3" = "#808080",
  "5" = "#404040"
)


padroes <- c("0" = "stripe", "1" = "none", "2" = "none",
             "3" = "none", "5" = "none")

df |>
  filter(!is.na(exp_car)) |>
  mutate(
    nivel = factor(nivel),
    exp_car = factor(exp_car, levels = c(0, 1, 2, 3, 5))
  ) |>
  count(nivel, exp_car) |>
  group_by(nivel) |>
  mutate(prop = n / sum(n)) |>
  ungroup() |>
  ggplot(aes(x = nivel, y = prop, fill = exp_car, pattern = exp_car)) +
  geom_col_pattern(
    position = position_fill(reverse = TRUE),
    colour = "black",
    linewidth = 0.2,
    pattern_fill = "gray30",
    pattern_colour = "gray30",
    pattern_density = 0.00001,
    pattern_spacing = 0.015,
    pattern_key_scale_factor = 0.6
  ) +
  scale_fill_manual(values = cores, labels = rotulos) +
```

```

scale_pattern_manual(values = padroes, labels = rotulos) +
scale_y_continuous(labels = scales::percent) +
labs(
  x = "Nível do cargo ocupado",
  y = "Proporção",
  fill = "exp_car",
  pattern = "exp_car",
  title = "Composição de exp_car por nível hierárquico"
) +
guides(
  fill = guide_legend(override.aes = list(
    pattern = c("stripe", "none", "none", "none", "none")
  )),
  pattern = "none"
) +
theme_bw(base_size = 10)

```



Como o valor 3 predominou nos níveis inferiores e o valor 5 cresceu monotonicamente até ser maioria no nível (DAS) 6, há indício de que eles de fato designam faixas distintas. Para checar se essa diferença é consistente e não apenas fruto do acaso, aplicamos o teste qui-quadrado de Pearson (χ^2), de modo a avaliar se a distribuição de 3 e 5 depende do nível hierárquico.

Testar o qui-quadrado de Pearson

```

tab <- df |>
  filter(exp_car %in% c(3, 5)) |>
  count(nivel, exp_car) |>
  tidyr::pivot_wider(names_from = exp_car, values_from = n, values_fill = 0) |>
  tibble::column_to_rownames("nivel") |>
  as.matrix()

```

```
tab
```

```
##      3    5
## 4 414  77
## 5  83 120
## 6  12  56
```

```
chisq.test(tab)
```

```
##
## Pearson's Chi-squared test
##
## data:  tab
## X-squared = 203.48, df = 2, p-value < 2.2e-16
```

O resultado ($\chi^2 = 203,48; gl = 2; p < 0,001$) permite que se rejeite a hipótese de independência, corroborando o diagnóstico segundo o qual os dois valores correspondem a faixas distintas (3-4 e 5-6) e dando suporte à imputação pela escala ancorada no piso de cada intervalo.

```
# Corrigir valores inadequados na variável 'exp_car' em df

df <- df |>
  mutate(
    exp_car_imputado = is.na(exp_car),
    exp_car = case_when(
      exp_car == 2 ~ 2,
      exp_car == 3 ~ 2,
      exp_car == 5 ~ 3,
      TRUE ~ exp_car
    )
  )

## Validar correção de valores inadequados na variável 'exp_car' em df

df |>
  group_by(exp_car) |>
  summarize(n = n(), .groups = "drop")
```

```
## # A tibble: 5 x 2
##   exp_car      n
##   <dbl> <int>
## 1      0   147
## 2      1    51
## 3      2   511
## 4      3   253
## 5     NA    76
```

Com relação à variável `instr`, notou-se codificações concorrentes para o nível de instrução “ensino superior completo”, quais sejam, `superior`, com 297 entradas; e `graduacao`, com 1 entrada). Para corrigir esse erro, este último rótulo foi eliminado, com sua entrada correspondente sendo anotada como `superior`.


```

# Corrigir valores inadequados na variável 'instr' em df

df <- df |>
  mutate(
    instr = case_when(
      instr == "graduacao" ~ "superior",
      TRUE ~ instr
    )
  )

## Validar correção de valores inadequados na variável 'instr' em df

df |>
  group_by(instr) |>
  summarize(n = n(), .groups = "drop")

```

```

## # A tibble: 6 x 2
##   instr      n
##   <chr>    <int>
## 1 doutorado    159
## 2 especializacao 203
## 3 mestrado    259
## 4 superior    298
## 5 tecnico     24
## 6 <NA>        95

```

Por fim, no tocante ao campo `indicacao`, observou-se que alguns registros estavam incoerentes com as datas de posse dos presidentes, trazendo um presidente que não correspondia à data de entrada no cargo (e.g., uma nomeação com entrada em 2005, ainda sob Lula, registrada como Rousseff).

```


posses <- as.Date(c("2011-01-01", "2016-05-12", "2019-01-01"))

cores <- c(
  "Lula"      = "white",
  "Rousseff"  = "grey80",
  "Temer"     = "grey55",
  "Bolsonaro" = "grey35"
)

df |>
  filter(!is.na(entrada), !is.na(indicacao)) |>
  mutate(
    entrada  = as.Date(entrada),
    indicacao = factor(indicacao,
                       levels = c("Lula", "Rousseff", "Temer", "Bolsonaro"))
  ) |>
  ggplot(aes(x = entrada, y = indicacao, fill = indicacao)) +
  geom_vline(xintercept = posses, linetype = "dashed",
            colour = "grey40", linewidth = 0.4) +
  geom_point(shape = 21, colour = "grey30", size = 1.8,
            alpha = 0.8, position = position_jitter(height = 0.15, width = 0)) +
  scale_fill_manual(values = cores) +
  scale_x_date(date_breaks = "2 years", date_labels = "%Y") +

```

```
labs(
  x = "Data de entrada no cargo",
  y = "Presidente registrado",
  fill = "Presidente",
  title = "Data de nomeação e presidente registrado"
) +
theme_bw(base_size = 9)
```



A correção consistiu em reatribuir o presidente a partir da data de entrada no cargo, que marca o momento da nomeação, comparando-a com o período de cada mandato.

```
# Corrigir valores inadequados na variável 'indicacao' em df

limites <- tibble::tibble(
  indicacao = c("Lula", "Rousseff", "Temer", "Bolsonaro"),
  inicio    = as.Date(c("2003-01-01", "2011-01-01", "2016-05-12", "2019-01-01")),
  fim       = as.Date(c("2010-12-31", "2016-05-11", "2018-12-31", "2022-12-31"))
)

df <- df |>
  mutate(
    entrada = as.Date(entrada),
    indicacao = case_when(
      entrada <= as.Date("2010-12-31") ~ "Lula",
      entrada <= as.Date("2016-05-11") ~ "Rousseff",

```

```

    entrada <- as.Date("2018-12-31") ~ "Temer",
    entrada <- as.Date("2022-12-31") ~ "Bolsonaro",
    TRUE ~ NA_character_
  )
)

## Validar correção de valores inadequados na variável 'indicacao' em df

df |>
  group_by(indicacao) |>
  summarize(n = n(), .groups = "drop")

```

```

## # A tibble: 5 x 2
##   indicacao      n
##   <chr>      <int>
## 1 Bolsonaro   393
## 2 Lula         92
## 3 Rousseff    358
## 4 Temer       190
## 5 <NA>         5

```

Verificar os casos <NA>

```

df |>
  filter(is.na(indicacao)) |>
  mutate(
    causa = case_when(
      is.na(entrada) ~ "entrada ausente",
      entrada > as.Date("2022-12-31") ~ "posterior ao recorte",
      TRUE ~ "outra"
    )
  ) |>
  select(chave, id, entrada, saida, causa)

```

```

## # A tibble: 5 x 5
##   chave          id  entrada saida          causa
##   <chr>      <chr> <date> <dtm>      <chr>
## 1 Agro-SPA-CGCCA1 SIFA  NA     2011-07-14 00:00:00 entrada ausente
## 2 Agro-SPA-CGOF1  SRPE  NA     2011-07-14 00:00:00 entrada ausente
## 3 Agro-SDI-CGCSA1 GHLO  NA     2020-07-22 00:00:00 entrada ausente
## 4 Agro-SDI-CGI1  MGSF  NA     2019-12-10 00:00:00 entrada ausente
## 5 Tecno-SETEC-S2  ATPRA NA     2014-08-25 00:00:00 entrada ausente

```

Validar graficamente a correção de valores inadequados na variável 'indicacao' em df

```

posses <- as.Date(c("2011-01-01", "2016-05-12", "2019-01-01"))


cores <- c(
  "Lula" = "white",
  "Rousseff" = "grey80",
  "Temer" = "grey55",
  "Bolsonaro" = "grey35"
)

```

```

)
df |>
  filter(!is.na(entrada), !is.na(indicacao)) |>
  mutate(
    entrada = as.Date(entrada),
    indicacao = factor(indicacao,
                       levels = c("Lula", "Rousseff", "Temer", "Bolsonaro"))
  ) |>
  ggplot(aes(x = entrada, y = indicacao, fill = indicacao)) +
  geom_vline(xintercept = posses, linetype = "dashed",
            colour = "grey40", linewidth = 0.4) +
  geom_point(shape = 21, colour = "grey30", size = 1.8,
            alpha = 0.8, position = position_jitter(height = 0.15, width = 0)) +
  scale_fill_manual(values = cores) +
  scale_x_date(date_breaks = "2 years", date_labels = "%Y") +
  labs(
    x = "Data de entrada no cargo",
    y = "Presidente registrado",
    fill = "Presidente",
    title = "Data de nomeação e presidente registrado"
  ) +
  theme_bw(base_size = 9)

```



3. Tabela descritiva: experiência administrativa

Crie uma variável binária para indicar experiência prévia em órgãos da administração pública. Use o *codebook* para justificar a escolha.

Essa variável já existe no *codebook* (`exp_adm`), no qual é definida como “experiência em órgãos da administração pública” e se indica que assume os valores 1 (sim) e 0 (não).

Depois, filtre a base para `orgao_sup` igual a `mapa` ou `minc` e apresente uma tabela com:

1. Número de observações válidas por pasta.
2. Número de pessoas/nomeações com experiência administrativa.
3. Proporção com experiência administrativa.
4. Intervalo de confiança de 95% para essa proporção.
5. Margem de erro associada ao intervalo de confiança.

```
# Exibir tabela com estatísticas de 'exp_adm' por pasta em df

df |>
  # Filtrar a base para as pastas do artigo ('mapa' e 'minc')
  filter(orgao_sup %in% c("mapa", "minc")) |>
  # Agrupar as operações por pasta
  group_by(orgao_sup) |>
  summarize(
    # Contar observações válidas (não-ausentes em 'exp_adm')
    n = sum(!is.na(exp_adm)),
    # Contar nomeações com experiência administrativa prévia
    k = sum(exp_adm == 1, na.rm = TRUE),
    # Calcular a proporção com experiência administrativa
    prop = k / n,
    # Extrair os limites inferior e superior do IC de 95% (método de Wilson)
    lower = prop.test(k, n, correct = FALSE)$conf.int[1],
    upper = prop.test(k, n, correct = FALSE)$conf.int[2],
    # Derivar a margem de erro a partir da amplitude do intervalo
    margem_erro = (upper - lower) / 2,
    .groups = "drop"
  ) |>
  # Formatar a saída como tabela para o PDF
  kable(
    digits = 3,
    col.names = c("Pasta", "N válido", "Com exp.", "Proporção",
                  "IC 95% (inf.)", "IC 95% (sup.)", "Margem de erro"),
    caption = "Experiência prévia em administração pública, por pasta"
  )
```

Tabela 1: Experiência prévia em administração pública, por pasta

Pasta	N válido	Com exp.	Proporção	IC 95% (inf.)	IC 95% (sup.)	Margem de erro
mapa	524	482	0.920	0.893	0.940	0.023
minc	354	312	0.881	0.844	0.911	0.034

Interprete os resultados em linguagem substantiva. A interpretação deve mencionar explicitamente o que significa o intervalo de confiança e o que significa a margem de erro.

A experiência prévia em administração pública é alta nas duas pastas. No MAPA, 482 das 524 nomeações válidas foram de pessoas que já haviam ocupado cargo público (92,0%). No MinC, foram 312 das 354 (88,1%). A diferença entre as duas fica em torno de 4 pontos percentuais, com o MAPA à frente.

O intervalo de confiança de 95% indica a faixa de valores plausíveis para a proporção real, dado que estamos trabalhando com uma amostra e não com o universo completo de nomeações. No MAPA, essa faixa vai de 89,3% a 94,0%. No MinC, de 84,4% a 91,1%. A leitura correta é: se repetíssemos esse procedimento de amostragem muitas vezes, cerca de 95% dos intervalos construídos dessa forma conteriam a proporção verdadeira.

A margem de erro mede a precisão da estimativa. Ela é a distância entre a proporção estimada e cada extremo do intervalo. No MAPA é de 2,3 pontos percentuais e no MinC de 3,4 pontos. O MinC tem margem maior porque sua base é menor (354 contra 524 observações), e amostras menores geram estimativas menos precisas.

4. Primeiro teste de hipótese bivariado

Teste a hipótese de que a proporção de nomeações com experiência administrativa é igual nas duas pastas.

Use a aproximação normal para a diferença entre proporções.

No relatório, apresente:

1. Hipótese nula.
2. Hipótese alternativa.
3. Teste usado no R.
4. P-valor.
5. Decisão usando nível de significância de 5%.
6. Interpretação substantiva.

Importante: não escreva apenas “rejeita” ou “não rejeita”. Explique o que o p-valor quer dizer nesse caso.

```
# Obter k e n por pasta

tab <- df |>
  group_by(orgao_sup) |>
  summarize(
    k = sum(exp_adm == 1, na.rm = TRUE),
    n = sum(!is.na(exp_adm)),
    p_hat = k / n,
    .groups = "drop"
  )

k1 <- tab$k[tab$orgao_sup == "minc"]
n1 <- tab$n[tab$orgao_sup == "minc"]
p1 <- tab$p_hat[tab$orgao_sup == "minc"]

k2 <- tab$k[tab$orgao_sup == "mapa"]
n2 <- tab$n[tab$orgao_sup == "mapa"]
p2 <- tab$p_hat[tab$orgao_sup == "mapa"]

# Obter a estatística z

p_pool <- (k1 + k2) / (n1 + n2)

z <- (p1 - p2) / sqrt(p_pool * (1 - p_pool) * (1/n1 + 1/n2))
```

```

p_value <- 2 * (1 - pnorm(abs(z)))

# Calcular o intervalo de confiança para a diferença

zcrit <- qnorm(0.975)

se_diff <- sqrt(p1*(1-p1)/n1 + p2*(1-p2)/n2)

ci_lower <- (p1 - p2) - zcrit * se_diff

ci_upper <- (p1 - p2) + zcrit * se_diff

# Exibir os resultados da análise

data.frame(
  k1 = k1, n1 = n1, p1 = p1,
  k2 = k2, n2 = n2, p2 = p2,
  p_pool = p_pool, z = z, p_value = p_value,
  diff = p1 - p2, ci_lower = ci_lower, ci_upper = ci_upper
)

```

```

##      k1  n1      p1  k2  n2      p2  p_pool      z  p_value      diff
## 1 312 354 0.8813559 482 524 0.9198473 0.904328 -1.902078 0.05716097 -0.0384914
##      ci_lower  ci_upper
## 1 -0.07942094 0.00243815

```

Testou-se a hipótese nula de que as duas pastas têm a mesma proporção de nomeações com experiência administrativa prévia, ou seja, de que a diferença entre elas é zero, contra a hipótese alternativa de que essas proporções diferem (teste bilateral). Utilizou-se, para tanto, o teste z para diferença entre duas proporções. A proporção foi de 92,0% no MAPA e 88,1% no MinC, uma diferença de 3,85 pontos percentuais a favor do MAPA, com p-valor de 0,057 ($z = -1,90$). Esse p-valor indica que, se as duas pastas tivessem de fato a mesma proporção, haveria cerca de 5,7% de chance de observar uma diferença tão grande quanto essa (ou maior) apenas por variação amostral. Como essa chance está acima do limiar de 5% que adotamos, não se rejeita a hipótese nula, e não há evidência suficiente para afirmar que as pastas diferem nesse aspecto. Vale notar que o resultado fica muito perto do limiar elegido, e o intervalo de confiança da diferença (de -7,94 a 0,24 pontos percentuais) inclui o zero por pouco. Os dados apontam, portanto, uma tendência de maior experiência prévia no MAPA, mas essa tendência não é forte o bastante para ser considerada estatisticamente robusta.

5. Segundo teste de hipótese bivariado

Crie uma variável chamada `alto_nivel`, igual a 1 quando `nivel` for 5 ou 6, e 0 quando `nivel` for 4.

```

# Criar a variável 'alto_nivel'

df <- df |>
  mutate(alto_nivel = case_when(
    nivel == 4 ~ 0,
    nivel == 5 ~ 1,
    nivel == 6 ~ 1,
    TRUE      ~ NA_real_
  ))

```

Compare a proporção de cargos de alto nível entre `mapa` e `minc`.

Use novamente a aproximação normal para a diferença entre proporções.

Apresente:

1. Uma tabela com as proporções por pasta.
2. Um intervalo de confiança de 95
3. Um teste de hipótese para a diferença entre as proporções.
4. O p-valor e sua interpretação.
5. Uma conclusão substantiva: a diferença parece grande, pequena ou irrelevante do ponto de vista substantivo?

```
# Obter k, n e proporção de cargos de alto nível por pasta ('mapa' e 'minc')
tab2 <- df |>
  filter(orgao_sup %in% c("mapa", "minc")) |>
  group_by(orgao_sup) |>
  summarize(
    k = sum(alto_nivel == 1, na.rm = TRUE),
    n = sum(!is.na(alto_nivel)),
    p_hat = k / n,
    .groups = "drop"
  )

# Separar os valores de cada pasta
k1 <- tab2$k[tab2$orgao_sup == "minc"]
n1 <- tab2$n[tab2$orgao_sup == "minc"]
p1 <- tab2$p_hat[tab2$orgao_sup == "minc"]
k2 <- tab2$k[tab2$orgao_sup == "mapa"]
n2 <- tab2$n[tab2$orgao_sup == "mapa"]
p2 <- tab2$p_hat[tab2$orgao_sup == "mapa"]

# Definir o valor crítico z para 95%
zcrit <- qnorm(0.975)

# Calcular o IC de 95% de cada proporção pela aproximação normal (Wald)
se1 <- sqrt(p1 * (1 - p1) / n1)
se2 <- sqrt(p2 * (1 - p2) / n2)
ci1 <- c(p1 - zcrit * se1, p1 + zcrit * se1)
ci2 <- c(p2 - zcrit * se2, p2 + zcrit * se2)

# Calcular a estatística z para a diferença de proporções (variância combinada)
p_pool <- (k1 + k2) / (n1 + n2)
z <- (p1 - p2) / sqrt(p_pool * (1 - p_pool) * (1/n1 + 1/n2))
p_value <- 2 * (1 - pnorm(abs(z)))

# Calcular o IC de 95% para a diferença entre as proporções (Wald)
se_diff <- sqrt(p1 * (1 - p1) / n1 + p2 * (1 - p2) / n2)
ci_lower <- (p1 - p2) - zcrit * se_diff
ci_upper <- (p1 - p2) + zcrit * se_diff

# Montar a tabela de proporções e ICs por pasta (itens 1 e 2)
tab_prop <- data.frame(
  orgao_sup = c("minc", "mapa"),
  k = c(k1, k2),
  n = c(n1, n2),
```



```

p_hat = c(p1, p2),
ci_inf = c(ci1[1], ci2[1]),
ci_sup = c(ci1[2], ci2[2])
)

# Exibir a tabela de proporções por pasta com IC de 95%
tab_prop |>
  kbl(
    digits = 3,
    booktabs = TRUE,
    col.names = c("Pasta", "Alto nível", "N válido", "Proporção",
                  "IC 95% (inf.)", "IC 95% (sup.)"),
    caption = "Proporção de cargos de alto nível (DAS 5-6) por pasta"
  ) |>
  kable_styling(latex_options = c("hold_position"))

```

Tabela 2: Proporção de cargos de alto nível (DAS 5-6) por pasta

Pasta	Alto nível	N válido	Proporção	IC 95% (inf.)	IC 95% (sup.)
minc	155	365	0.425	0.374	0.475
mapa	187	525	0.356	0.315	0.397

```

# Montar a tabela do teste de diferença de proporções (itens 3 e 4)
tab_diff <- data.frame(
  diff = p1 - p2,
  z = z,
  p_value = p_value,
  ci_lower = ci_lower,
  ci_upper = ci_upper
)

# Exibir os resultados do teste z para a diferença entre as proporções
tab_diff |>
  kbl(
    digits = 3,
    booktabs = TRUE,
    col.names = c("Diferença (MinC - MAPA)", "Estatística z", "P-valor",
                  "IC 95% (inf.)", "IC 95% (sup.)"),
    caption = "Teste z para a diferença de proporções entre as pastas"
  ) |>
  kable_styling(latex_options = c("hold_position"))

```

Tabela 3: Teste z para a diferença de proporções entre as pastas

Diferença (MinC - MAPA)	Estatística z	P-valor	IC 95% (inf.)	IC 95% (sup.)
0.068	2.065	0.039	0.003	0.134

A proporção de cargos de alto nível (DAS 5-6) foi de 42,5% no MinC e 35,6% no MAPA, uma diferença de 6,8 pontos percentuais a favor do MinC. O teste z resultou em p-valor de 0,039 ($z = 2,065$). Esse p-valor indica

que, se as duas pastas tivessem de fato a mesma proporção, haveria cerca de 3,9% de chance de observar uma diferença tão grande quanto essa (ou maior) apenas por variação amostral. Como essa chance está abaixo do limiar de 5%, rejeita-se a hipótese nula, e há evidência de que as pastas diferem. O intervalo de confiança da diferença, de 0,3 a 13,4 pontos percentuais, não inclui o zero, o que é coerente com a rejeição.

Do ponto de vista substantivo, a diferença é moderada. São cerca de 7 pontos percentuais a mais de cargos de alto escalão no MinC, um contraste significativo. Entretanto, o intervalo de confiança é largo (de 0,3 a 13,4 pontos), de modo que a diferença pode ser pequena ou expressiva. Em síntese, há diferença, mas a amostra não permite “cravar” seu tamanho.

6. Significância estatística e nível de significância

Escolha um dos dois testes anteriores e responda:

1. A conclusão mudaria se o nível de significância fosse 10%?
2. A conclusão mudaria se o nível de significância fosse 1%?
3. O que esse exercício mostra sobre a diferença entre p-valor e significância substantiva?

Tomando por referência o primeiro teste de hipótese bivariado, sobre a proporção de nomeações com experiência administrativa nas duas pastas (p-valor de 0,057; $z = -1,90$), a conclusão mudaria ao nível de significância de 10%, já que 0,057 fica abaixo desse limiar e levaria a rejeitar a hipótese nula, ao contrário da decisão tomada a 5%. Ao nível de 1%, a conclusão não mudaria, pois 0,057 permanece acima de 0,01 e a hipótese nula continuaria não rejeitada. Essa distinção mostra que a decisão depende do limiar de significância adotado, que é *convencionado* — e não uma propriedade dos dados. O mesmo p-valor produz três leituras conforme o nível escolhido, mas a diferença observada entre as pastas continua a mesma (em torno de 4 pontos percentuais). O p-valor mede a probabilidade de observar essa diferença caso não houvesse distinção real, ao passo que a relevância substantiva depende da magnitude e do contexto. Para determinar esta última, o foco não recai, portanto, sobre o limiar convencionado; depende, em realidade, de uma avaliação empiricamente contextualizada (*i.e.*, se 4 pontos percentuais de experiência administrativa a mais no MAPA têm peso substantivo para entender os perfis burocráticos das duas pastas).

7. O que aconteceria se a amostra fosse maior?

Escolha uma das proporções estimadas nas perguntas anteriores.

Suponha que a proporção observada fosse a mesma, mas o número de observações fosse duas vezes maior.

Responda:

1. O que tenderia a acontecer com o erro-padrão?
2. Por que isso acontece?

Tomando por referência o segundo teste de hipótese bivariado, sobre a proporção de cargos de alto nível (DAS 5-6) nas duas pastas, escolhe-se a proporção estimada para o MinC (42,5%, com 155 cargos de alto nível em 365 observações válidas). Caso a proporção observada permanecesse a mesma, mas o número de observações dobrasse, o erro-padrão tenderia a diminuir. Isso ocorre porque o erro-padrão de uma proporção é dado por $\sqrt{p(1-p)/n}$, de modo que o n aparece no denominador, sob a raiz. Como a proporção p seguiria idêntica, apenas o n mudaria, e dobrá-lo reduziria o erro-padrão por um fator de $\sqrt{2}$ (cerca de 29%). A intuição por trás disso é que amostras maiores fornecem estimativas mais precisas da proporção real, reduzindo a incerteza em torno dela. Como consequência, o intervalo de confiança ficaria mais estreito e a margem de erro menor, ainda que a estimativa pontual não se alterasse.

Perguntas exclusivas para pós-graduação

P1. Unidade de análise: nomeação ou indivíduo?

A base tem a nomeação como unidade de análise, mas uma mesma pessoa pode aparecer mais de uma vez. Construa uma versão da base com uma linha por id. Explique a regra usada para lidar com pessoas que aparecem mais de uma vez. Depois, repita um dos testes obrigatórios.

Responda:

1. O resultado muda quando a unidade passa de nomeação para indivíduo?
2. Qual unidade de análise é mais adequada para a pergunta que você está respondendo?

```
# Construir a base de dados no nível da chave 'id' + 'orgao_sup'

df_pessoa <- df |>
  filter(orgao_sup %in% c("mapa", "minc")) |>
  mutate(
    entrada = as.Date(entrada),
    saida   = as.Date(saida)
  ) |>
  arrange(id, orgao_sup, entrada) |>
  group_by(id, orgao_sup) |>
  summarize(
    n_nomeacoes      = n(),
    chaves             = paste(chave, collapse = "; "),
    nivel_primeiro     = first(nivel),
    nivel_max          = max(nivel, na.rm = TRUE),
    alto_nivel_max     = as.integer(any(nivel %in% c(5, 6))),
    setores            = paste(unique(setor), collapse = "; "),
    n_setores          = n_distinct(setor),
    area               = first(area),
    inst_ensino         = first(inst_ensino),
    inst_origem         = first(inst_origem),
    instr_primeiro     = first(instr),
    instr_final         = last(instr),
    partido_primeiro   = first(partido),
    partido_mudou      = as.integer(n_distinct(partido[!is.na(partido)]) > 1),
    n_partidos          = n_distinct(partido[!is.na(partido)]),
    car_pub_primeira   = first(car_pub),
    car_pub_mudou      = as.integer(n_distinct(car_pub) > 1),
    indicacao_primeira = first(indicacao),
    n_presidentes       = n_distinct(indicacao),
    UF_primeira         = first(`UF*`),
    UF_mudou            = as.integer(n_distinct(`UF*`[!is.na(`UF*`)]) > 1),
    partido_pr_prim     = first(partido_pr),
    partido_ministro_prim = first(partido_ministro),
    cargo_ele_prev      = first(cargo_ele),
    cargo_ele_ever      = as.integer(any(cargo_ele == 1, na.rm = TRUE)),
    lid_part_prev       = first(lid_part),
    lid_part_ever       = as.integer(any(lid_part == 1, na.rm = TRUE)),
    exp_adm_prev        = first(exp_adm),
    exp_adm_ever        = as.integer(any(exp_adm == 1, na.rm = TRUE)),
    exp_mer_prev        = first(exp_mer),
    exp_mer_ever        = as.integer(any(exp_mer == 1, na.rm = TRUE)),
    exp_soc_prev        = first(exp_soc),
    exp_soc_ever        = as.integer(any(exp_soc == 1, na.rm = TRUE)),
    exp_car_prev        = first(exp_car),
    exp_car_max         = max(exp_car, na.rm = TRUE),
```

```

    entrada_primeira = min(entrada, na.rm = TRUE),
    saida_ultima     = max(saida, na.rm = TRUE),
    perm_total       = sum(perm, na.rm = TRUE),
    perm_media       = mean(perm, na.rm = TRUE),
    .groups = "drop"
)

## Warning: There were 145 warnings in `summarize()`.
## The first warning was:
## i In argument: `exp_car_max = max(exp_car, na.rm = TRUE)` .
## i In group 1: `id = "AAMA"` `orgao_sup = "minc"` .
## Caused by warning in `max()` :
## ! nenhum argumento não faltante para max; retornando -Inf
## i Run `dplyr::last_dplyr_warnings()` to see the 144 remaining warnings.

# Reperformar o primeiro teste de hipótese bivariado

tab_pp <- df_pessoa |>
  group_by(orgao_sup) |>
  summarize(
    k = sum(exp_adm_prev == 1, na.rm = TRUE),
    n = sum(!is.na(exp_adm_prev)),
    p_hat = k / n,
    .groups = "drop"
)

k1 <- tab_pp$k[tab_pp$orgao_sup == "minc"]
n1 <- tab_pp$n[tab_pp$orgao_sup == "minc"]
k2 <- tab_pp$k[tab_pp$orgao_sup == "mapa"]
n2 <- tab_pp$n[tab_pp$orgao_sup == "mapa"]

prop.test(c(k1, k2), c(n1, n2), correct = FALSE)

##
## 2-sample test for equality of proportions without continuity correction
##
## data:  c(k1, k2) out of c(n1, n2)
## X-squared = 1.9712, df = 1, p-value = 0.1603
## alternative hypothesis: two.sided
## 95 percent confidence interval:
## -0.1019347  0.0174448
## sample estimates:
##   prop 1    prop 2
## 0.8299595 0.8722045

```

Para obter uma linha por pessoa, agrupamos por `id` combinado com `orgao_sup`. A escolha de incluir a pasta no agrupamento resolve o caso de indivíduos que atuaram nos dois ministérios (duas pessoas na base). Assim, em vez de forçá-los a uma pasta só, cada combinação pessoa-pasta gera uma linha, o que preserva a informação sobre ambas as pastas e mantém a coerência com um teste que compara os ministérios entre si.

As variáveis foram tratadas conforme seu comportamento ao longo das nomeações de cada pessoa. As de identificação e da nomeação específica (`chave`, `setor`, `cargo`, `nivel`) foram condensadas em resumos da trajetória, como `n_nomeacoes`, `nivel_max` e `alto_nivel_max`, preservando as chaves originais de modo

concatenado (;). Os atributos estáveis dos nomeados (`area`, `inst_ensino`, `inst_origem`) foram mantidos pelo seu valor único; para `instr`, que pode sofrer alterações se a pessoa se titula no período, guardamos o valor inicial e o final. Os atributos que mudam entre nomeações e cuja mudança é informativa (`partido`, `car_pub`, `indicacao`, `UF*`) receberam um valor de referência somado a variáveis que registram a mudança, como `partido_mudou` e `n_partidos`. Por fim, as dicotômicas de experiência (`cargo_ele`, `lid_part`, `exp_adm`, `exp_mer`, `exp_soc`) foram bifurcadas em duas versões, dado que são medidas a cada nomeação: uma `_prev`, com o estado na primeira nomeação (experiência prévia à entrada), e uma `_ever`, indicando se o atributo se tornou verdadeiro (1) em algum momento (experiência adquirida ao longo da trajetória).

O teste repetido foi o primeiro teste bivariado, sobre a proporção com experiência administrativa nas duas pastas, usando a variável `exp_adm_prev`. Optou-se por ela (e não por `exp_adm_ever`), para manter continuidade com o teste original por nomeação, que também media experiência prévia à nomeação; assim, a comparação entre as duas versões isola o efeito da mudança de unidade de análise. A proporção com experiência administrativa prévia foi de 87,2% no MAPA e 83,0% no MinC, uma diferença de cerca de 4 pontos percentuais, com p-valor de 0,160. Como esse valor está acima do limiar de 5%, não se rejeita a hipótese nula, e o intervalo de confiança da diferença (de -10,2 a +1,7 pontos) inclui o zero.

Vale contrastar com o teste original por nomeação, cujo p-valor foi 0,057, próximo do limiar. Ao passar para uma linha por pessoa, o número de observações diminui e a diferença perde significância estatística, ainda que sua magnitude permaneça parecida. Isso separa as duas noções de significância. A diferença substantiva entre as pastas é praticamente a mesma nos dois casos, em torno de 4 pontos; o que muda é apenas a significância estatística, sensível ao tamanho da amostra. Em ambos, contudo, a conclusão se mantém, *i.e.*, não há evidência sólida de que as pastas difiram quanto à experiência administrativa prévia. Para a pergunta de fundo, pode-se dizer que a base por pessoa é a unidade mais adequada, já que o interesse recai sobre o perfil dos indivíduos que ocupam as pastas, não sobre cada nomeação isolada. Contar a mesma pessoa várias vezes infla a amostra e trata como independentes observações que efetivamente não o são.

P2. Intervalo de confiança para diferença de proporções

Em vez de apresentar apenas intervalos de confiança separados por pasta, calcule um intervalo de confiança para a diferença entre as proporções.

Interprete a diferença em pontos percentuais e diga se o intervalo inclui zero.

```
# Testar a diferença de proporções (exp_adm_prev) entre as pastas, no nível da pessoa
res_pp <- prop.test(c(k1, k2), c(n1, n2), correct = FALSE)

# Extrair o IC de 95% para a diferença (MinC - MAPA) e converter para pontos percentuais
diff_pp      <- res_pp$estimate[1] - res_pp$estimate[2]
ci_diff      <- res_pp$conf.int

data.frame(
  diff_pp_pp  = diff_pp * 100,
  ci_inf_pp   = ci_diff[1] * 100,
  ci_sup_pp   = ci_diff[2] * 100,
  inclui_zero = ci_diff[1] < 0 & ci_diff[2] > 0
)

##          diff_pp_pp ci_inf_pp ci_sup_pp inclui_zero
## prop 1  -4.224496 -10.19347   1.74448         TRUE
```

A diferença entre as proporções (calculada no sentido MinC menos MAPA), é de -4,2 pontos percentuais, *i.e.*, a proporção de pessoas com experiência administrativa prévia é cerca de 4 pontos menor no MinC que

no MAPA. O intervalo de confiança de 95% para essa diferença vai de -10,2 a +1,7 pontos percentuais. Como o intervalo inclui o zero, não é possível afirmar que as pastas diferem quanto a essa proporção. O valor real da diferença pode ser negativo (menos experiência no MinC), mas também pode ser nulo ou até ligeiramente positivo. Isso é coerente com o p-valor de 0,160 obtido no teste, e reforça a mesma conclusão por outra via, já que um intervalo que cruza o zero equivale a não rejeitar a hipótese nula ao nível de 5%.